NumPy 인공신경망 직접 구현
MNIST 분류 실험 보고서

황태하 | 머신러닝의 이해 및 실습 과제

최종 테스트 정확도 97.4600% · 검증 정확도 97.1503% · 모델 784 → 128 → 10

목차

1. 과제 개요 및 목적 / 2. MNIST 데이터셋 소개 / 3. 개발 환경 및 사용 기술 ... 1쪽

4. 직접 설계한 신경망 / 5. 은닉층과 노드 수 선정 이유 ... 2쪽

6. 순전파와 역전파의 원리 / 7. 손실 함수와 가중치 업데이트 ... 2쪽

8. 학습 과정 및 하이퍼파라미터 / 9. 기준 모델 학습 결과 ... 3쪽

10. 정확도 개선 실험 / 11. 실험 결과 비교표 및 그래프 ... 4쪽

12. 최종 모델의 테스트 정확도 ... 5쪽

13. 혼동 행렬 및 오분류 분석 ... 6쪽

14. 정확도 개선 원인과 결과 해석 / 15. 결론 및 한계점 ... 7쪽

1. 과제 개요 및 목적

손글씨 숫자의 특징을 학습하는 MLP를 NumPy로 직접 구현했다. 은닉층의 크기·깊이와 학습 설정을 비교하고, 역전파로 가중치와 편향을 갱신하여 공식 테스트 정확도 80% 이상을 목표로 했다. 자동미분과 프레임워크의 모델 학습 기능은 사용하지 않았다.

2. MNIST 데이터셋 소개

MNIST는 28×28 흑백 숫자 0~9로 구성된다. 공식 학습 60,000개를 고정 시드의 층화 분할로 훈련 49,999개, 검증 10,001개로 나눴다. 클래스별 반올림 때문에 검증 수는 정확히 10,000개와 한 개 차이가 난다. 공식 테스트 10,000개는 최종 선택 후 평가했다.

픽셀은 0~255에서 0~1로 정규화하고 784차원 벡터로 변환했다. Keras 공식 배포 파일의 SHA-256을 확인했다. 검증·테스트로 전처리 통계나 모델 파라미터를 추정하지 않았다.

3. 개발 환경 및 사용 기술

Windows / Python 3.14.4 / NumPy 2.4.6 / pandas 3.0.3 / Matplotlib 3.10.9. Jupyter 커널에서 전체 셀을 순차 실행했다. seed=42, BLAS 스레드=1로 고정했다. 보고서는 실행 결과를 사용해 ReportLab으로 작성했다.

4. 직접 설계한 신경망 구조

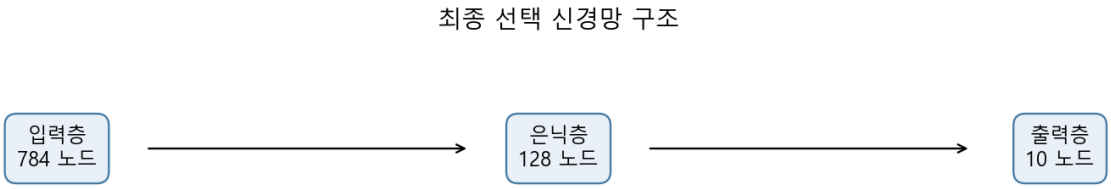


그림 1. 검증 성능을 기준으로 선택한 최종 MLP 구조

계층	연결	활성화	가중치 수	편향 수	파라미터 합
1층	784 → 128	ReLU	100,352	128	100,480
2층	128 → 10	Softmax	1,280	10	1,290

학습 가능한 전체 파라미터는 101,770개다. 입력층은 784개 픽셀을 전달하며 은닉층이 비선형 특징 조합을 학습한다. 출력층의 10개 노드는 숫자별 logits를 계산하고 Softmax로 클래스 확률을 만든다.

5. 은닉층과 노드 수 선정 이유

기준 은닉층 128개와 64·256개, 두 은닉층 128→64를 비교했다. 이 실험 범위에서 E5의 검증 정확도 97.1503%가 가장 높아 784 → 128 → 10를 채택했다. 모델 크기와 시간도 함께 기록했으나 최종 선택의 우선 기준은 검증 정확도이며, 동률일 때 검증 손실과 파라미터 수를 사용했다.

6. 순전파와 역전파의 원리

순전파: Z = A·W + b, 은닉층 A = max(0, Z). 배치 B개에서 A의 모양은 B×입력 노드 수, W는 입력×출력 노드 수, b는 출력 노드 수다. ReLU는 계산이 단순하고 양수 영역에서 기울기를 유지한다.

출력 미분: delta = (P - Y) / B. 가중치 기울기는 dW = A.T @ delta, 편향 기울기는 db = sum(delta, axis=0)다. 이전 층으로는 delta_prev = (delta @ W.T) * (Z_prev > 0)를 전달한다. 여기서 @는 행렬곱, .T는 전치, *는 원소별 곱이다. 모든 기울기를 계산한 뒤 파라미터를 갱신한다.

float64 중앙차분(eps=1e-05)으로 두 은닉층의 전체 55개 파라미터를 검증했다. 최대 스케일 오차는 3.979e-11로 허용치 1e-6보다 작았다. 큰 logits의 수치 안정성, SGD 손실 감소, 데이터 분할, 지표 예제를 포함한 5개 검사도 통과했다.

7. 손실 함수와 가중치 업데이트 방법

Softmax는 배타적인 10개 클래스의 확률을 표현하고, Cross-Entropy는 정답 확률이 작을수록 큰 손실을 부여한다. logits에서 행별 최댓값을 뺀 s에 대해 L = 평균[log(sum(exp(s))) - s정답]으로 계산해 overflow와 log(0)을 방지한다.

He 초기화 W ~ N(0, 2/fan_in), 편향 0을 사용했다. 미니배치 SGD는 W = W - lr * dW, b = b - lr * db로 갱신한다. lr은 학습률이다. 모멘텀·가중치 감쇠·데이터 증강은 사용하지 않았다.

8. 학습 과정 및 하이퍼파라미터

모든 실험은 같은 훈련·검증 분할과 10에포크 예산을 사용했다. 매 에포크 훈련 순서를 섞었으며, 초기화와 셔플에 고정 난수 시드를 사용했다. 훈련 지표는 갱신을 끝낸 모델로 전체 훈련 집합에서 다시 계산했다.

최우수 검증 에포크의 가중치를 메모리에 보관한 뒤 복원했다. 동률이면 검증 손실이 낮은 에포크를 선택했다. 시간에는 미니배치 갱신과 훈련·검증 평가가 포함된다. 배치 변경은 에포크당 갱신 횟수도 바꾸므로 동일 갱신 횟수 비교는 아니다.

구조	학습률	배치	총 에포크	초기화 / 활성화 / 손실 / 최적화
784 → 128 → 10	0.01	64	10	He / ReLU·Softmax / CE / SGD

9. 기준 모델 학습 결과

기준 E1의 선택 에포크는 10이며 훈련 정확도 93.3319%, 검증 정확도 92.5607%, 검증 손실 0.257183였다. 총 시간은 9.74초다.

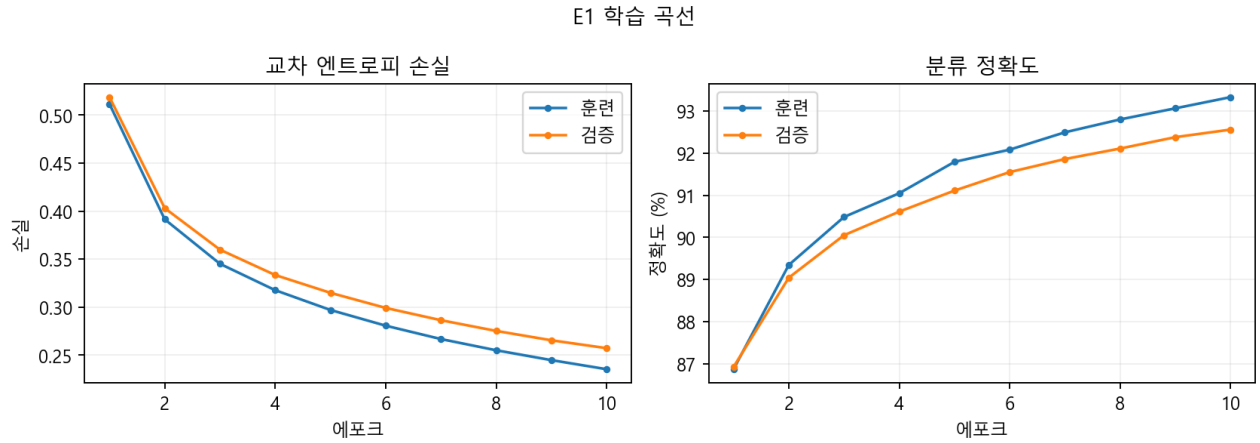


그림 2. 기준 모델의 에포크별 손실과 정확도

Epoch	훈련 손실	검증 손실	훈련 정확도	검증 정확도	시간(초)
1	0.5116	0.5188	86.8677%	86.9213%	1.06
2	0.3914	0.4031	89.3438%	89.0411%	0.98
3	0.3451	0.3598	90.4838%	90.0510%	0.98
4	0.3176	0.3334	91.0478%	90.6109%	0.98
5	0.2970	0.3149	91.7938%	91.1109%	0.96
6	0.2806	0.2991	92.0838%	91.5508%	0.95
7	0.2667	0.2863	92.4958%	91.8608%	0.97
8	0.2550	0.2752	92.8019%	92.1108%	0.96
9	0.2447	0.2654	93.0659%	92.3808%	0.94
10	0.2353	0.2572	93.3319%	92.5607%	0.94

10. 정확도 개선 실험

E1에서 주요 변수 하나씩만 바꿨다. E2는 은닉 노드 64개, E3은 256개, E4는 학습률 0.001, E5는 0.1, E6는 은닉층 128→64, E7은 배치 128이다. 나머지 설정은 기준과 같다. 동일 구조는 같은 초기 가중치에서 시작했으며 개선되지 않은 실험도 모두 포함했다.

11. 실험 결과 비교표 및 그래프

정확도·손실은 각 실험에서 선택된 에포크의 값이다. Ep는 선택/총 에포크이며 시간은 10에포크 전체다. Δ는 기준 E1 대비 검증 정확도 변화(%p)다. 구조는 입력·은닉·출력 노드를 모두 표시한다.

실험	구조	LR	B	Ep	훈련 %	검증 %	검증 손실	초	Δ%p
E1	784-128-10	0.01	64	10/10	93.33	92.56	0.2572	9.7	+0.00
E2	784-64-10	0.01	64	10/10	93.11	92.36	0.2675	5.3	-0.20
E3	784-256-10	0.01	64	10/10	93.70	93.10	0.2489	20.1	+0.54
E4	784-128-10	0.001	64	10/10	86.99	86.85	0.5171	9.5	-5.71
E5	784-128-10	0.1	64	10/10	98.62	97.15	0.0939	9.8	+4.59
E6	784-128-64-10	0.01	64	10/10	95.07	94.13	0.1985	11.2	+1.57
E7	784-128-10	0.01	128	10/10	91.69	91.09	0.3137	9.5	-1.47

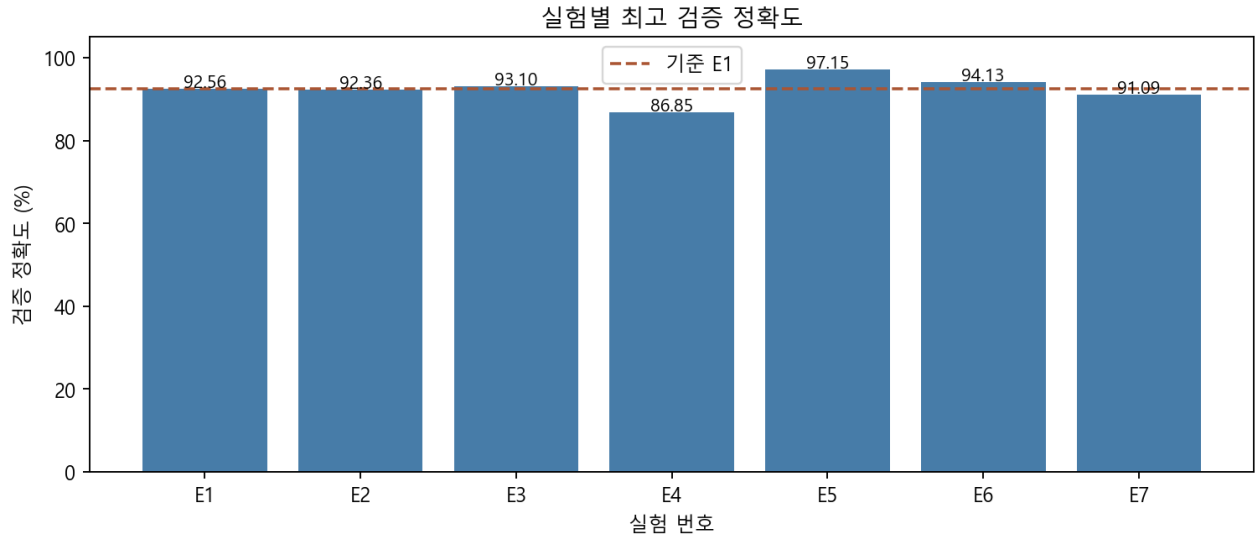


그림 3. 실험별 최고 검증 정확도와 기준 모델(E1)

E1: 기준 대비 0.00%p 동일. 비교 기준이다.

E2: 기준 대비 0.20%p 하락. 노드 감소로 파라미터와 표현 용량이 함께 감소한다.

E3: 기준 대비 0.54%p 상승. 넓은 은닉층은 표현 용량을 늘리지만 연산량도 증가한다.

E4: 기준 대비 5.71%p 하락. 작은 학습률은 같은 에포크 예산에서 갱신 폭이 작아 수렴이 느릴 수 있다.

E5: 기준 대비 4.59%p 상승. 큰 학습률은 갱신 폭을 키워 수렴 속도를 바꾸지만 불안정해질 가능성도 있다.

E6: 기준 대비 1.57%p 상승. 깊이를 늘려 비선형 조합 단계를 추가하지만 최적화와 계산 비용도 달라진다.

E7: 기준 대비 1.47%p 하락. 배치 증가로 에포크당 갱신 횟수가 줄어드는 효과도 함께 포함된다.

12. 최종 모델의 테스트 정확도

검증만으로 선택한 E5 (784 → 128 → 10)를 고정한 후 테스트 10,000개를 한 번 추론했다. 그 예측을 재사용해 모든 최종 지표와 그림을 계산했다. 테스트 결과를 보고 모델을 바꾸거나 재선택하지 않았다.

지표	실제 측정값
Test Accuracy	97.4600%
정답 수 / 테스트 수	9,746 / 10,000
Test Loss	0.084811
Macro Precision	0.974517
Macro Recall	0.974397
Macro F1-score	0.974415
80% 이상 달성	달성

Precision·Recall·F1은 클래스별 값을 각각 구한 뒤 10개 클래스를 동일 가중치로 평균했다. F1은 클래스별 F1의 평균이며 macro precision과 macro recall의 조화평균이 아니다.

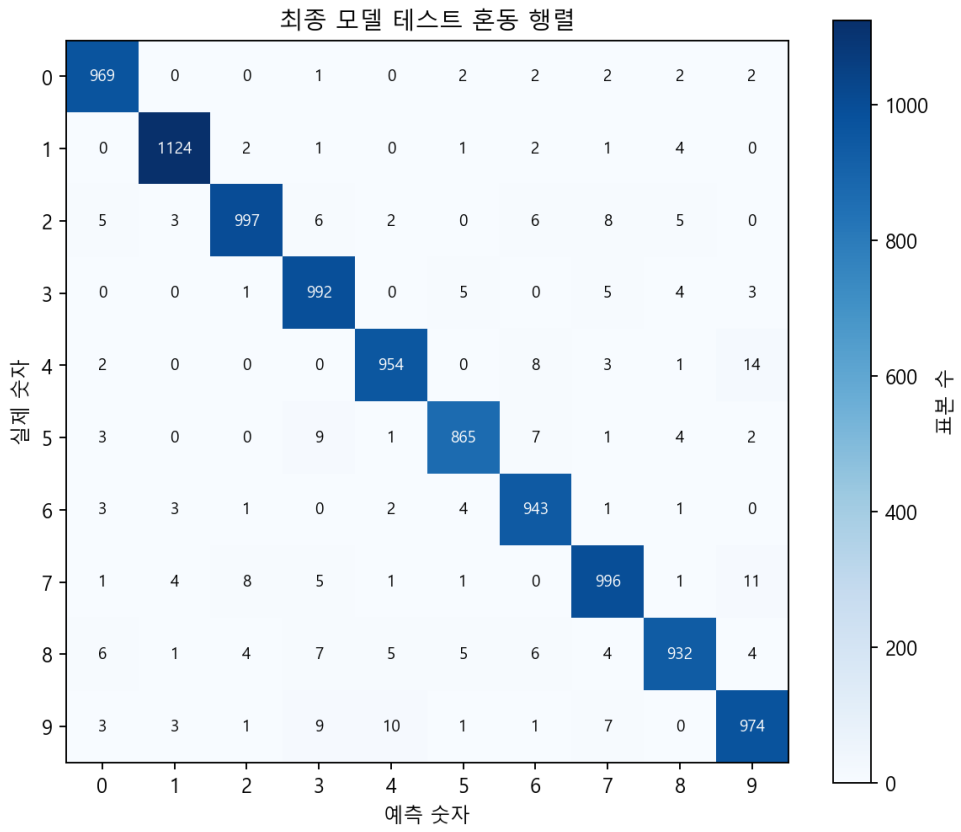


그림 4. 테스트 혼동 행렬: 행은 실제 숫자, 열은 예측 숫자

13. 혼동 행렬 및 오분류 분석

혼동 행렬 대각선은 정분류, 비대각선은 오분류다. 아래 사례는 테스트 순서상 처음 15개 오분류를 표시한 것으로, 임의로 쉬운 사례만 선택하지 않았다.

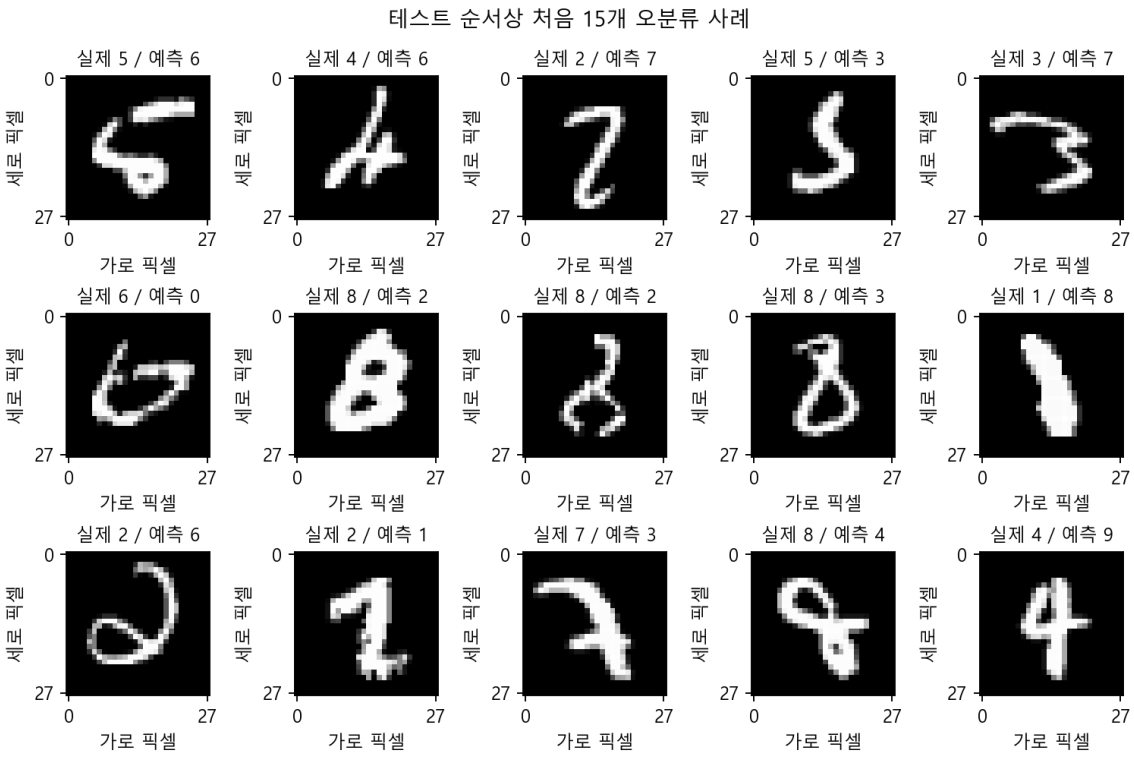


그림 5. 실제 레이블과 예측이 다른 손글씨 숫자 사례

빈도가 높은 실제→예측 오분류: 4→9 14개, 7→9 11개, 9→4 10개, 9→3 9개, 5→3 9개.

획의 연결·기울기·모양이 유사한 숫자 사이의 혼동을 살펴볼 수 있다. 다만 이미지 관찰은 정성적 해석이며 각 오류의 원인을 확정하는 인과 분석은 아니다.

숫자	Precision	Recall	F1-score	테스트 표본 수
0	0.9768	0.9888	0.9828	980
1	0.9877	0.9903	0.9890	1135
2	0.9832	0.9661	0.9746	1032
3	0.9631	0.9822	0.9725	1010
4	0.9785	0.9715	0.9750	982
5	0.9785	0.9697	0.9741	892
6	0.9672	0.9843	0.9757	958
7	0.9689	0.9689	0.9689	1028
8	0.9769	0.9569	0.9668	974
9	0.9644	0.9653	0.9648	1009

14. 정확도 개선 원인과 실험 결과 해석

기준 E1의 검증 정확도는 92.5607%이고, 최종 E5는 97.1503%로 +4.59%p 변화했다. 최종 모델은 784 → 128 → 10 구조이며, 학습률 0.1, 배치 64, 총 10에포크 중 10에포크가 선택되었다. 이 비교 범위에서 검증 정확도가 가장 높아 해당 은닉층 개수와 노드 수를 채택했다. 선택 에포크의 훈련-검증 정확도 차이는 1.47%p다. 테스트는 9,746/10,000개를 맞혀 97.4600%이며, 80% 목표 달성이다.

학습률만 0.01에서 0.1로 높인 E5는 같은 예산에서 검증 손실이 0.2572에서 0.0939로 낮아졌다. 아래 곡선에서 훈련·검증 손실이 함께 감소해 이 범위에서는 큰 학습률이 더 빠른 학습에 유리했다고 해석할 수 있다. 반면 학습률 0.001은 수렴이 느렸다. 노드 증가·층 추가도 개선됐지만 E5보다 낮았다. 단일 시드 결과이므로 여러 시드에서도 같은 순위라고 단정할 수 없다.

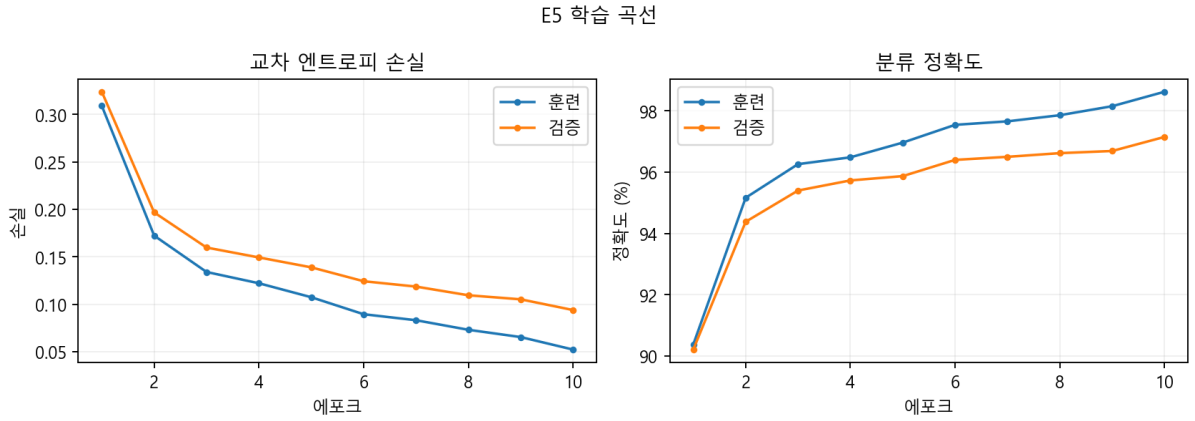


그림 6. 최종 선택 모델의 훈련·검증 학습 곡선

초기 상태 대비 선택된 에포크의 파라미터 변화는 다음과 같다. 가중치 변화는 Frobenius norm, 편향 변화는 L2 norm이다. 실제 학습 갱신을 확인하는 지표이며 변화량만으로 성능을 설명할 수는 없다.

층	가중치 변화 L2	가중치 상대 변화	편향 변화 L2
1	11.089699	0.690521	0.760531
2	7.623845	1.678466	0.420838

15. 결론 및 한계점

NumPy로 순전파·역전파·미니배치 SGD를 직접 구현하고 7가지 조건을 실제 학습했다. 최종 테스트 정확도 97.4600%로 80% 목표를 달성했다. 전체 코드와 결과는 함께 제출하는 노트북에 포함된다.

한계는 단일 시드, 10에포크 예산, 이미지의 공간 구조를 직접 활용하지 않는 MLP다. 같은 검증 집합으로 여러 조건을 선택했으므로 검증 성능에도 선택 편향이 있을 수 있다. 향후 여러 시드의 평균·표준편차, 학습률 스케줄, 정규화, 데이터 증강, CNN을 별도 실험으로 비교할 수 있다.

참고 자료

Keras MNIST 문서: https://keras.io/api/datasets/mnist/
공식 로더·해시: https://github.com/keras-team/keras/blob/master/keras/src/datasets/mnist.py
데이터 배포: https://storage.googleapis.com/tensorflow/tf-keras-datasets/mnist.npz